



Attention Is All You Need

Yapay Zekada Bir Devrim: Tekrarlayan Sinir Ağlarının
(RNN) Saltanatını Yıkan Makale

Makale Kimlik Kartı & Yol Haritamız

Attention Is All You Need

Yazar(lar): Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, Illia Polosukhin

Yıl / Konferans: 2017 / NIPS (Conference on Neural Information Processing Systems)

Link: <https://arxiv.org/abs/1706.03762>

Alan Etiketi: Transformer Tabanlı Dil Modeli, Makine Çevirisi, Diziden-Diziye (Seq2Seq) Modeller



Problem: Neden yeni bir yaklaşıma ihtiyaç vardı?



Ana Fikir: Transformer'ın devrimci çözümü neydi?



Modelin Kalbi: Attention mekanizması nasıl çalışır?




Kanıtlar: Sonuçlar ne kadar etkileyici?



Miras: Bu makale neden bugün bile bu kadar önemli?

Problem: Sıralı İşlemenin Zincirleri



Makine çevirisi gibi görevlerde o güne kadarki en iyi yaklaşımlar **Tekrarlayan Sinir Ağları (RNN'ler)** idi.

RNN'ler, bir cümleyi kelime kelime, yani **sırayla** işler. Tıpkı domino taşları gibi: bir sonraki kelimeyi işlemek için bir öncekinin bitmesini beklemek zorundasınız.

Makalenin de belirttiği gibi, bu 'doğası gereği sıralı' (inherently sequential) yapı, iki büyük engelle yol açıyordu:

1. **Parallelleştirme Engeli:** Modern donanımların (GPU) gücü tam olarak kullanılamıyordu. İşlemler paralel yürütülemediği için modellerin eğitimi çok yavaştı.
2. **Uzun Mesafe Bağımlılık Sorunu:** Cümlenin başındaki bir kelime ile sonundaki bir kelime arasındaki bağlantı, bilgi zincir boyunca ilerlerken zayıflıyor veya 'unutuluyordu'.

(Mini Özet: RNN'lerin sıralı yapısı hem yavaşlığa hem de uzun cümlelerde bilgi kaybına neden oluyordu. Bu makale, bu temel sorunu ortadan kaldırmayı hedefledi.)

Ana Fikir: Tekrarlayan Yapıyı Tamamen Ortadan Kaldırmak

"Tekrarlayan ve evrişimli yapıları tamamen ortadan kaldırarak, yalnızca dikkat (attention) mekanizmalarına dayanan, Transformer adında yeni ve basit bir ağ mimarisi öneriyoruz."



Ana Katkıları:

1. **RNN'siz Mimari:** Tekrarlayan (recurrent) katmanlar tamamen terk edildi. Modelin temeli, cümledeki kelime ilişkilerini tartan **Self-Attention** mekanizmasıdır.
2. **Multi-Head Attention (Çok Başlı Dikkat):** Modelin, bir cümledeki farklı anlamsal ve sözdizimsel özelliklerine aynı anda odaklanmasını sağlayan güçlü bir yapı sunuldu.
3. **Positional Encoding (Konumsal Kodlama):** Sıralı işlem olmadığı için kaybolan kelime sırası bilgisini, modelin girişine ekleyen zekice bir yöntem geliştirildi.
4. **Parallelleşme ve Hız:** Bu yeni mimari, çok daha fazla paralelleştirilebildiği için eğitim sürelerini önemli ölçüde kısalttı.


Transformer Mimarisi: Kodlayıcı-Kodçözücü Yapısı

Kodlayıcı-Kodçözücü Yapısı

Transformer, bir Kodlayıcı (Encoder) ve bir Kodçözücü (Decoder) yığınınından oluşur.

2. Kodlayıcı (Encoder Stack, N=6):

- Giriş cümlesini alır ve her kelime için bağlamsal bir temsil oluşturur.
- Her katmanda iki alt katman bulunur: **Multi-Head Self-Attention** ve **Position-wise Feed-Forward Network**.
- Her alt katman etrafında **Residual Connection** ve **Layer Normalization** kullanılır.



3. Kodçözücü (Decoder Stack, N=6):

- Encoder'dan gelen temsilleri ve o ana kadar üretilmiş hedef kelimeleri kullanarak bir sonraki kelimeyi tahmin eder.
- Encoder katmanlarına ek olarak, kaynak cümlelerin hangi kelimelerine odaklanacağını belirleyen bir **Encoder-Decoder Attention** katmanı daha içerir.
- Gelecekteki kelimeleri görmesini engellemek için self-attention katmanı **maskelenmiştir**.


Modelin Kalbi: Scaled Dot-Product Attention

Sezgisel Açıklama

Attention, bir bilgi veritabanında arama yapmaya benzer.

- **Query (Q - Sorgu)**: O an ilgilendiğimiz kelime. ("Aradığım şey bu.")
- **Keys (K - Anahtarlar)**: Karşılaştırma yapacağımız diğer tüm kelimeler. ("Bunların içinden arayacağım.")
- **Values (V - Değerler)**: Yine diğer tüm kelimeler. ("Eğer bir anahtar sorgumla eşleşirse, onun değerini alacağım.")

Mekanizma, Sorgu'nun her bir Anahtar ile ne kadar uyumlu olduğunu (dot product) ölçer. Bu uyum skorlarına göre Değerler'i ağırlıklı olarak toplar.



$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{Q * K^T}{\sqrt{d_k}} \right) * V$$

Semboller Tablosu

Sembol	Anlamı
Q, K, V	Sorgu, Anahtar, Değer Matrisleri. Kelime temsillerini içeren matrisler.
$\sqrt{d_k}$	Ölçekleme Faktörü. Key vektörlerinin boyutu (d_k). Makaleye göre bu ölçekleme, d_k büyüdüğünde dot product sonuçlarının çok büyümesini engelleyerek softmax fonksiyonunu stabil bölgelerde bölgelerde tutar ve eğitimi kolaylaştırır.
softmax	Softmax Fonksiyonu. Hesaplanan uyum skorlarını, toplamı 1 olan bir dikkat ağırlığı dağılımına dönüştürür.

Daha Güçlü Bir Bakış: Multi-Head Attention



Single-Head Attention



Multi-Head Attention

Sezgisel Açıklama

Tek bir attention ile bakmak, bir cümlenin sadece bir tür ilişkisine odaklanmak gibidir.

Multi-Head Attention ise Q , K ve V vektörlerini h kadar farklı 'uzman başlığa' (head) gönderir. Her başlık, farklı bir doğrusal projeksiyonla (*learned linear projection*) veriyi farklı bir 'temsil alt uzayına' (*representation subspace*) taşır ve attention'ı orada uygular.

Makaleye göre bu yapı, 'modelin farklı pozisyonlardaki farklı temsil alt uzaylarından gelen bilgilere ortaklaşa dikkat etmesine olanak tanır.'

Bu çalışmada $h = 8$ paralel attention başlığı kullanılmıştır.

Formül Özeti

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_n) * W^O$$


burada:

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

(Mini Özet: Attention, bir 'Sorgu'nun diğer 'Anahtar'larla ilgisini ölçerken, Multi-Head Attention bunu birden çok farklı 'bakış açısıyla' aynı anda yaparak daha zengin bir anlama kapasitesi sağlar.)

Mimarinin Diğer Kilit Taşları

1. Positional Encoding (Kelime Sırasını Unutmamak)




Problem: Modelde tekrarlayan veya evrişimli yapı olmadığı için kelime sırası bilgisi doğal olarak mevcut değildir.

Çözüm: Giriş vektörlerine (embeddings), kelimenin pozisyonunu belirten özel bir “konumsal kodlama” vektörü eklenir.

Nasıl?: Farklı frekanslardaki sinüs ve kosinüs fonksiyonları kullanılır: $PE(pos, 2i) = \sin(pos/10000^{2i/d_{model}})$ ve $PE(pos, 2i+1) = \cos(pos/10000^{2i/d_{model}})$. Bu yöntem, modelin göreceli pozisyonları öğrenmesini kolaylaştırır.

2. Position-wise Feed-Forward Networks (FFN)



Attention katmanından çıkan sonuçlar, her kelime pozisyonu için ayrı ayrı ama aynı parametrelerle basit bir ileri beslemeli sinir ağına (FFN) sokulur.

Görevi: $FFN(x) = \max(0, xW_1 + b_1)W_2 + b_2$. Attention'ın ürettiği temsilleri işlemek ve doğrusal olmayan bir dönüşüm uygulamak. Bu, modelin daha karmaşık fonksiyonlar öğrenmesini sağlar.

Neden Self-Attention? Hız, Verimlilik ve Uzun Mesafe Bağlantıları

Makale, self-attention katmanlarının teorik üstünlüklerini üç ana kritere göre değerlendirir:

1. ****Katman Başına Hesaplama Karmaşıklığı***: Bir katmandaki toplam işlem sayısı.
2. ****Sıralı İşlem Sayısı***: Parallellendirilemeyen minimum işlem sayısı. Bu, eğitim hızının anahtarıdır.
3. ****Maksimum Yol Uzunluğu***: Ağdaki herhangi iki pozisyon arasındaki en uzun sinyal yolu. Kısa olması, uzun mesafe bağımlılıklarını öğrenmeyi kolaylaştırır.

Katman Tipi	Katman Başına Karmaşıklık	Sıralı İşlemler	Maksimum Yol Uzunluğu
Self-Attention	$O(n^2 \cdot d)$	$O(1)$	$O(1)$
Recurrent (RNN)	$O(n \cdot d^2)$	$O(n)$	$O(n)$
Convolutional (CNN)	$O(k \cdot n \cdot d^2)$	$O(1)$	$O(\log_k(n))$

Çıkarım: Self-attention, tüm pozisyonları **sabit sayıda sıralı işlemle** birbirine bağlar ve aralarındaki yol uzunluğunu **minimumda (1)** tutar. Bu, onu hem daha hızlı (parallellendirilebilir) hem de uzun cümleleri anlamada teorik olarak daha güçlü kılar.

Kanıt: Makine Çevirisinde Kırılan Rekorlar

Deney Ortamı

- Veri Seti: WMT 2014 English-to-German & English-to-French
- Metrik: **BLEU Puanı** (Yüksek olan daha iyidir)

İngilizce-Almanca (EN-DE) Çeviri Performansı (BLEU)



Çarpıcı Sonuçlar

Model	EN-DE BLEU	EN-FR BLEU	Eğitim Maliyeti (FLOPs)
GNMT + RL (Google's RNN)	26.30	41.16	$\sim 1.8 \cdot 10^{20}$
ConvS2S (Facebook's CNN)	26.36	41.29	$\sim 7.7 \cdot 10^{19}$
Transformer (Big Model)	28.4	41.8	$\sim 2.3 \cdot 10^{19}$

Yorum

- Transformer, İngilizce-Almanca çeviride, o güne kadarki en iyi modelleri ve hatta bu modellerin birleşiminden oluşan 'ensemble'ları bile **2.0 BLEU puanı gibi ezici bir farkla** geçti.
- Bu yeni başarı standardını, rakiplerinin **eğitim maliyetinin çok küçük bir kısmıyla** elde etti. (Örn: 8 P100 GPU ile 3.5 gün).

Sadece Çeviri Değil: Diğer Gönevlerde Genelleme


Transformer'ın sadece makine çevirisi için değil, diğer doğal dil işleme görevleri için de güçlü bir mimari olduğunu kanıtlamak amacıyla İngilizce Cümle Yapısı Ayrıştırma (English Constituency Parsing) görevinde de denendi.

Zorluklar

- Çıktı, girdiden çok daha uzun ve yapısal kısıtlamalara sahip.
- RNN tabanlı modeller bu görevde zorlanıyordu.

Sonuçlar

- Transformer, sadece 40 bin cümlelik WSJ veri setiyle eğitildiğinde bile, önceki birçok modelden daha iyi performans göstererek **91.3 F1 skoruna** ulaştı.
- Daha büyük bir veri setiyle (yarı denetimli) eğitildiğinde ise **92.7 F1 skoru** ile o dönemki en iyi sonuçlardan birini elde etti.



(Mini Özet: Transformer, makine çevirisinde rekor kırmakla kalmadı, aynı zamanda yapısal olarak zorlu bir görevde de başarılı olarak çok yönlü ve güçlü bir mimari olduğunu kanıtladı.)

Güçlü ve Zayıf Yönler: Eleştirel Bir Bakış

+ Güçlü Yanlar


1. **Maksimum Parallelleştirme:** Sıralı işlem olmadığı
 - için eğitim süresi dramatik ölçüde azalır.
2. **Sabit Yol Uzunluğu ($O(1)$):** Uzak kelimeler
 - arasındaki bilgi akışı tek adımdır, bu da uzun mesafe bağımlılıklarını öğrenmeyi çok kolaylaştırır.
3. **Üstün Performans:** Hem daha hızlı hem de
 - daha isabetli sonuçlarla yeni bir SOTA standardı belirledi.
4. **Genellenebilirlik:** Çeviri, ayrıştırma ve daha
 - sonra görüleceği üzere neredeyse tüm NLP görevleri için temel bir yapı taşı haline geldi.

— Zayıf Yanlar

1. **Karesel Karmaşıklık ($O(n^2)$):** Self-attention'ın
 - hesaplama maliyeti, cümlenin uzunluğunun (n) karesiyle artar. Bu, çok uzun belgeleri (kitaplar, makaleler) tek seferde işlemlerini zorlaştırır.
2. **Veri İhtiyacı:** RNN'lere kıyasla en iyi
 - performansı göstermek için genellikle daha büyük veri setlerine ihtiyaç duyar.
3. **Doğal Olmayan Konum Bilgisi:** Kelime sırası
 - bilgisi, mimarının doğal bir parçası değildir; 'Positional Encoding' gibi dışarıdan bir eklemeyeyle sağlanır.

Miras: Transformer'ın Başlattığı Çağ

'Attention Is All You Need' sadece bir makine çevirisi makalesi değildi; günümüzün en güçlü yapay zeka modellerini ateşleyen bir kıvılcımdı. **Transformer mimarisi**, aşağıdaki gibi sayısız alanda devrim yarattı:



****Sonuç*:** Bu mimari, günümüzün üretken yapay zeka devriminin temelini oluşturmaktadır.

Sezgisel Özet: "Kalabalık Bir Partide Konuşmayı Anlamak"



Eski Yöntem (RNN)

Eski Yöntem (RNN): Partideki herkesi sırayla dinlemek gibidir. İlk kişiyi dinler, aklınızda tutar, sonra ikinciye geçersiniz. Konuşma uzadıkça ilk kişinin ne dediğini unutmaya başlarsınız. Yavaş ve verimsiz!



Transformer Yöntemi (Self-Attention)

Transformer Yöntemi (Self-Attention): Odadaki herkesi aynı anda duyabiliyorsunuz. Biri 'O, dün bana verdiği kitabı çok beğendiğini söyledi' dediğinde, beyniniz anında şunları yapar:

1. **"O" kelimesini duyunca (Query):** Dikkatinizi hemen daha önce adı geçen kişiye ('Ayşe') yöneltirsiniz (Key).
2. **"kitabı" kelimesini duyunca:** Dikkatinizi 'verdiği' ve 'beğendiğini' kelimelerine yöneltirsiniz.

Transformer da tam olarak bunu yapar. Bir kelimeyi anlamak için, cümledeki geri kalanındaki en ilgili kelimelere anında **'dikkatini yöneltir'** (with accent color #E67E22). Sıra değil, ilgi önemlidir.

Multi-Head ise partideki farklı sohbet konularını aynı anda takip edebilen birden fazla kulağınızın olması gibidir!

Öğrenmeyi Pekiştirme: Kilit Sorular

1. Transformer mimarisi, RNN'lerin hangi iki temel sorununu çözmek için geliştirilmiştir?
2. 'Self-Attention' mekanizmasının temelindeki **Query, Key ve Value** kavramlarını kendi cümlelerinizle bir örnek üzerinden açıklayınız.
3. Eğer modelde 'Positional Encoding' kullanmasaydık ne gibi bir problem ortaya çıkardı?
4. Attention mekanizması neden $\sqrt{dk}$ ile ölçeklenir? Makaleye göre bunun eğitim sürecindeki rolü nedir?



5. Decoder'daki 'masked' self-attention neden gereklidir? Bu maskeleye olmasaydı model ne öğrenirdi?
6. Transformer'ın en büyük zayıflığı olan $O(n^2)$ karmaşıklığı, bu mimarinin hangi tür görevlerde kullanılmasını zorlaştırır?
7. Bu makale neden 'Attention is All You Need' (İhtiyacınız Olan Tek Şey Dikkat) başlığını taşıyor? Bu başlık, dönemin yaygın kanısına nasıl meydan okuyor?